Podstawy maszynowego uczenia na przykładzie klasyfikacji tekstu

Sztuczna Inteligencja i Inżyniera Wiedzy. Ćwiczenie 4

Michał Hetmańczuk

27 05 2020

Sprawozdanie powstało jak dokument typu R Markdown.

Etap 1

Data processing

W pierwszej kolejności rozpakowano piliki zip.

Następnie umieszczono zawartość plików w strukturze danych typu Data Frame. Z nazwy pliku wyekstrahowano kategorię dokumentu. Referencja na tak utworzoną strukturę. została nazwana 'texts_df'.

Opis struktury:

```
str(texts_df, vec.len = 0)
```

```
## 'data.frame':    9837 obs. of  2 variables:
##  $ category: Factor w/ 34 levels "Albania","Amerykanscy-prozaicy",..: NULL ...
##  $ text    : chr   ...
```

```
levels(texts_df$category)
```

```
##  [1] "Albania"
##  [2] "Amerykanscy-prozaicy"
##  [3] "Arabowie"
##  [4] "Astronautyka"
##  [5] "Choroby"
##  [6] "Egipt"
##  [7] "Ekologia-roslin"
##  [8] "Filmy-animowane"
##  [9] "Galezie-prawa"
## [10] "Gry-komputerowe"
## [11] "Karkonosze"
## [12] "Katolicyzm"
## [13] "Komiksy"
## [14] "Komputery"
## [15] "Kotowate"
## [16] "Kultura-Chin"
## [17] "Monety"
## [18] "Muzyka-powazna"
## [19] "Narciarstwo"
```

```
## [20] "Narkomania"
## [21] "Niemieccy-wojskowi"
## [22] "Optyka"
## [23] "Pierwiastki-chemiczne"
## [24] "Pilka-nozna"
## [25] "Propaganda-polityczna"
## [26] "Rachunkowosc"
## [27] "Samochody"
## [28] "Samoloty"
## [29] "Sporty-silowe"
## [30] "System-opieki-zdrowotnej-w-Polsce"
## [31] "Szachy"
## [32] "Wojska-pancerne"
## [33] "Zegluga"
## [34] "Zydzi"
```

Aby ujednolcić tekst oraz wstępnie usunąć potencjalnie zbędne cechy, dane zostały wyczyszczone poprzez usunięcie: wielkich liter, liczb, znaków interpunkcyjnych, zbędnych białych znaków oraz wyrazów ze stop-listy (plik stopwords.txt z polską stop-listą został zaczerpnięty z https://github.com/bieli/stopwords/blob/master/polish.stopwords.txt). Aby wykorzystać w tym celu funkcję tm_map, zawartość dokumentów umieszczono w przeznaczonej do tego strukturze - VCorpus (taki typ danych jest obsługiwany przez tm_map).

```
text_labels <- texts_df$category
text_corpus <- VCorpus(VectorSource(texts_df$text))
text_corpus_clean <- text_corpus %>%
  tm_map(content_transformer(tolower)) %>%
  tm_map(removeNumbers) %>%
  tm_map(removePunctuation) %>%
  tm_map(stripWhitespace)
stopwords.pl <- readLines(".\\stopwords.txt", encoding = 'UTF-8')
text_corpus_clean <- tm_map(text_corpus_clean, removeWords, stopwords.pl)
```

Wykorzystując tak wyczyszczone korpusy dokumentów utworzono macierz pojęć, zawierającą częstotliwości występowania danego pojęcia w danym dokumencie.

```
text_dtm <- DocumentTermMatrix(text_corpus_clean)
text_dtm
```

```
## <<DocumentTermMatrix (documents: 9837, terms: 264253)>>
## Non-/sparse entries: 1524005/2597932756
## Sparsity           : 100%
## Maximal term length: 173
## Weighting          : term frequency (tf)
```

Przykładowe wizualizacje przygotowanych danych. Kategorie: “Albania”, “Choroby”, “Astronautyka”

Propozycja metody selekcji cech i implementacji modeli

Ze względu na fakt, iż mamy do czynienia z szukaniem zależności między dwoma kategorycznymi zmiennym, selekcja cech zostanie przeprowadzona z wykorzystnaiem testów X^2. Implementacja klaysfikatora Naiwnego Bayesa zostanie zaczerpnięta z biblioteki "fastNaiveBayes". Biblioteka tak obsługuje wszystkie rodzaje klasyfikatora (Bernoulli, Gaussiam, Mulitnomial), co może być bardzo przydatne z perspektywy przeprowadzania badań. Wykorzystana zostanie również implementacja drzewa decyzyjnego z pakietu "tree".

Naive-Bayes

Model został zaimplementowany w następujący sposób: Wykonany trening z wykorzystaniem 10-krotnej walidacji krzyżowej, wywołując funkcję z wybranej wcześniej biblioteki fastNaiveBayes

Badanie wpływu liczby wybranych cech na wynik działania modelu

```
nfeatures = seq(100, 5000, by = 100)
results = vector()

for(i in nfeatures){
  results = c(results, performNaiveBayes(i, 0)[2])
}

plot(nfeatures, results)
```

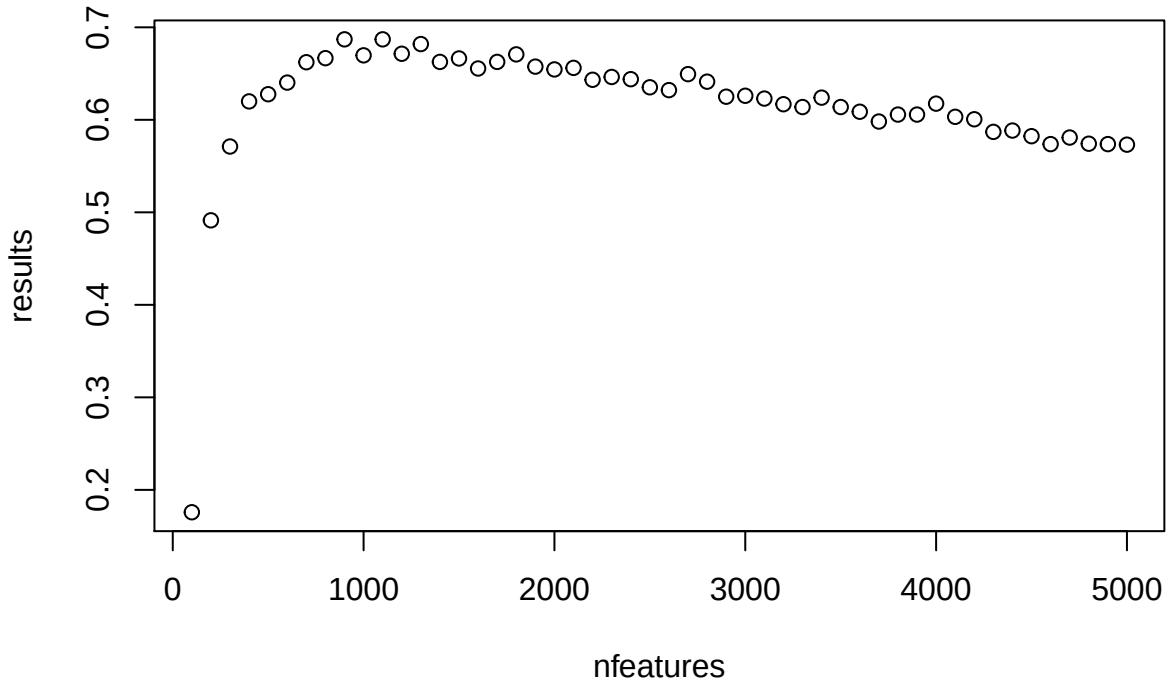


```
nfeatures = seq(1000, 2000, by = 10)
results = vector()

for(i in nfeatures){
  results = c(results, performNaiveBayes(i, 0)[2])
}

plot(nfeatures, results)
```

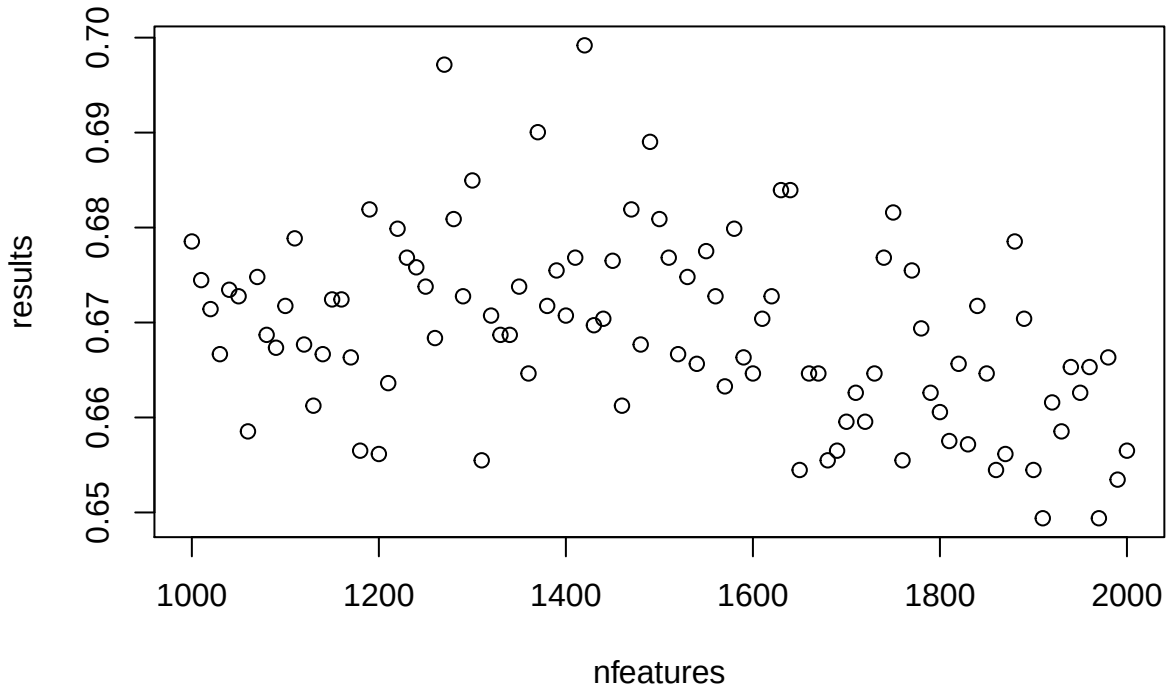

Badanie wpływu współczynnik wygładzania laplace'a na wynik działa modelu

```
laplaces = seq(0,10, by = 0.1)
results = vector()

for(i in laplaces){
  results = c(results, performNaiveBayes(1350, i)[2])
}

plot(laplaces, results)
```

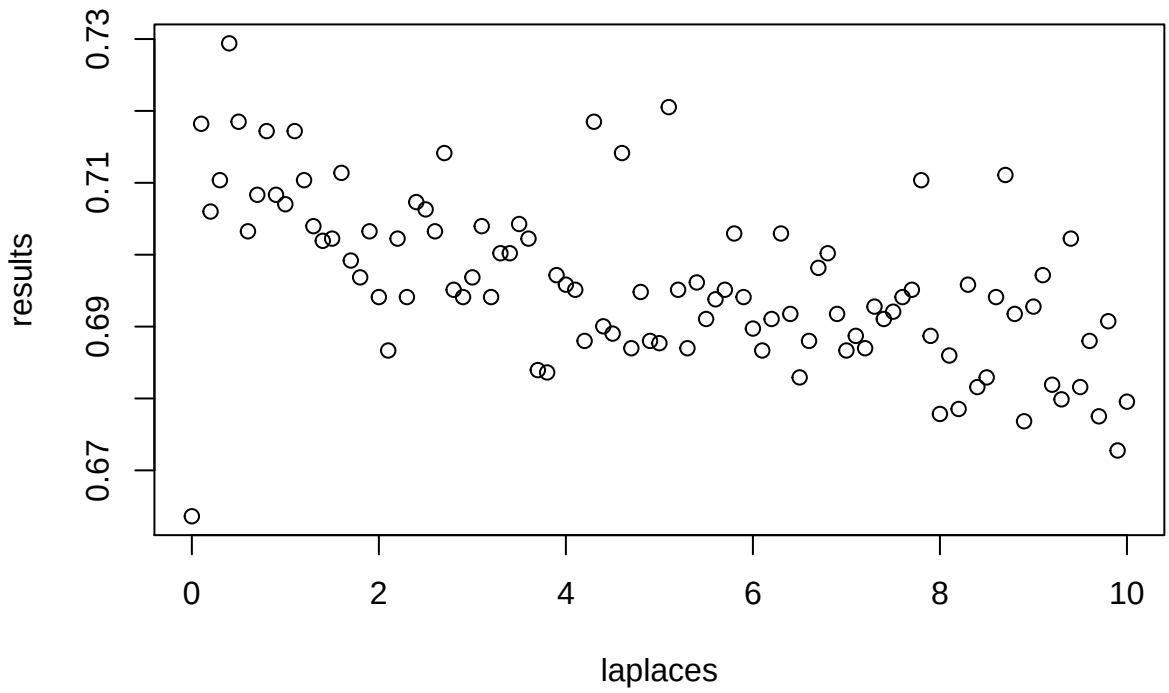

Wyniki badań

Najlepsze wyniki osiągnięto dla 1350 cech oraz współczynnika 0.5

```
results = vector()
for(i in 1:10){
  results = c(results, performNaiveBayes(1350, 0.5)[2])
}

mean(unlist(results, use.names=FALSE))
```

```
## [1] 0.7043506
```

Decision tree

Wybrana biblioteka ma już wbudowaną 10-krotną walidację krzyżową Uwaga! Niestety ze względu na nieznane wcześniej ograniczenia wybranej biblioteki - można wykorzystać maksymalnie 32 kategorie. Odrzucono dwie kategorie oraz opisywane przez nie dokumenty.

```
chi2vals <- dfm_group(fs_dfm) %>%
textstat_keyness(measure = "chi2")
chi2vals$chi2 <- abs(chi2vals$chi2)
chi2vals <- chi2vals[order(-chi2vals$chi2), ]
```

```
dfmTop <- dfm_select(fs_dfm, chi2vals$feature[1:1000])

texts_freq_df <- as.data.frame(dfmTop)
texts_freq_df$category <- as.factor(text_labels)
colnames(texts_freq_df) <- make.names(colnames(texts_freq_df))
texts_freq_df <- texts_freq_df[,!duplicated(colnames(texts_freq_df))]
texts_freq_df <- texts_freq_df[,!(names(texts_freq_df) == '-')]
texts_freq_df <- texts_freq_df[!(texts_freq_df$category %in% c('Albania', 'Zydzi')),]
texts_freq_df$category <- drop.levels(texts_freq_df$category)
colnames(texts_freq_df) <- make.names(colnames(texts_freq_df))

model <- tree(category ~ ., data = texts_freq_df)
summary(model)
```

```
##
## Classification tree:
## tree(formula = category ~ ., data = texts_freq_df)
## Variables actually used in tree construction:
##  [1] "ur"         "samolot"    "karkonosze" "moneta"     "chemiczny"
##  [6] "gry"        "czołgów"    "samochód"   "wersja"     "wyniki"
## [11] "serii"      "kot"        "szachowa"   "zm"
## Number of terminal nodes:  15
## Residual mean deviance:  4.719 = 43520 / 9223
## Misclassification error rate: 0.6941 = 6412 / 9238
```

```
pred <- predict(model, texts_freq_df[,!names(texts_freq_df) == 'category'], type = 'class')

sum(pred == texts_freq_df$category)/length(pred)
```

```
## [1] 0.3059104
```